



МИНОБРНАУКИ РОССИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«МИРЭА – Российский технологический университет»
РТУ МИРЭА

Институт информационных технологий (ИИТ)
Кафедра прикладной математики (ПМ)

ОТЧЕТ ПО ПРАКТИЧЕСКОЙ РАБОТЕ
по дисциплине «Технологии и инструментарий анализа больших данных»

Практическая работа № 1

Студент группы *ИКБО-50-23, Враженко Д.О.*

(подпись)

Проверил *Старший преподаватель,
Приходько Н.А.*

(подпись)

Отчет представлен «__» _____ 2026 г.

Москва 2026 г.

Постановка задачи

Источник датасета

Для выполнения самостоятельной работы выбран набор данных «Дорожно-транспортные происшествия: координаты, участники и пострадавшие». Прямая ссылка: https://tochno.st/datasets/traffic_accidents.

Использован файл accidents_all_regions_126_v20260901.csv – выгрузка, содержащая сведения о ДТП в России за период с 2015 по 2026 год. Для учебных целей из всего набора взяты первые 500 строк, чтобы обеспечить быструю обработку и наглядность анализа. Общий объём исходного файла превышает 1 ГБ, но урезанная версия (501 строка с заголовком) позволяет выполнить все этапы работы без задержек вычислений.

Цель анализа

Целью настоящей работы является проведение полного цикла разведочного анализа данных (EDA) на примере датасета о ДТП. В рамках работы необходимо:

- оценить структуру и качество данных (пропуски, дубликаты, типы);
- оптимизировать представление данных для экономии памяти;
- создать новые вычисляемые признаки, углубляющие анализ;
- выявить статистические закономерности (группировки, корреляции, выбросы);
- визуализировать ключевые распределения и взаимосвязи;
- экспортировать очищенные данные в различные форматы и сравнить их эффективность.

Краткая предметная постановка

Данные содержат информацию о дорожно-транспортных происшествиях, зафиксированных на территории РФ. В набор входят 18 признаков, среди которых:

- категория ДТП (столкновение, наезд на пешехода, опрокидывание и др.);
- географические координаты (долгота, широта);
- временная метка (дата и время);
- условия (освещение, погода, состояние дороги);
- количество участников, погибших и раненых.

Выбранный датасет полностью соответствует требованиям к самостоятельной работе: содержит >500 строк, >5 информативных столбцов,

не менее двух числовых и одного категориального признаков, а также имеет временную метку и пропуски, что позволяет продемонстрировать навыки предобработки.

Паспорт данных

Размер таблицы: 500 строк, 18 столбцов

Перечень признаков и их предполагаемый смысл:

id	: Уникальный идентификатор ДТП (целое число)
tags	: Тематический тег — всегда "Дорожно-транспортные происшествия" (категориальный)
category	: Тип ДТП (например, Столкновение, Наезд на пешехода, Наезд на препятствие и т.д.) — категориальный
region	: Регион РФ (категориальный)
county	: Район или город (категориальный)
address	: Адрес происшествия (текстовый)
longitude	: Географическая долгота (числовой, float)
latitude	: Географическая широта (числовой, float)
nearby	: Наличие объектов поблизости (текстовый, могут быть пропуски)
datetime	: Дата и время ДТП (строка, будет преобразована в datetime)
light	: Условия освещения (категориальный)
weather	: Погодные условия (категориальный, могут быть пропуски)
road_conditions	: Состояние дорожного покрытия (категориальный, могут быть пропуски)
participants_count	: Количество участников ДТП (целое число)
participant_categories	: Категории участников (например, "Все участники", "Пешеходы") — категориальный
severity	: Тяжесть происшествия (Лёгкий, Тяжёлый) — категориальный
dead_count	: Число погибших (целое число)
injured_count	: Число раненых (целое число)

Типы данных, распознанные при загрузке:

id	int64
tags	str
category	str
region	str
county	str

address	str
longitude	float64
latitude	float64
nearby	str
datetime	str
light	str
weather	str
road_conditions	str
participants_count	int64
participant_categories	str
severity	str
dead_count	int64
injured_count	int64

dtype: object

Качество и предобработка

Пропуски по столбцам (количество NaN)

id	0
tags	0
category	0
region	0
county	0
address	13
longitude	0
latitude	0
nearby	0
datetime	0
light	0
weather	0
road_conditions	0
participants_count	0
participant_categories	0
severity	0
dead_count	0
injured_count	0

dtype: int64

Количество полных дубликатов

0

Число уникальных значений по каждому столбцу

id	: 500
tags	: 1
category	: 9
region	: 1
county	: 9
address	: 402
longitude	: 434
latitude	: 406
nearby	: 28
datetime	: 499
light	: 6

```
weather          : 10
road_conditions   : 18
participants_count : 11
participant_categories : 8
severity          : 3
dead_count        : 4
injured_count     : 9
```

До оптимизации: 0.38 MiB

После оптимизации: 0.25 MiB

Снижение: 33.9%

Типы после оптимизации:

```
id              int32
tags            str
category        category
region          str
county          category
address         str
longitude       float64
latitude        float64
nearby          str
datetime        str
light           category
weather         category
road_conditions category
participants_count int8
participant_categories category
severity        category
dead_count      int8
injured_count   int8
dtype: object
```

Оптимизация типов (преобразование категориальных в category, целочисленных в int8, id в int32) уменьшила память с 0.38 МБ до 0.25 МБ (снижение на 33.9%). Это показывает, что грамотный выбор dtype важен для эффективной работы с данными.

EDA

7. Создать минимум один вычисляемый признак с явной формулой или логическим правилом и объяснить его смысл.

```
opt_df['datetime'] = pd.to_datetime(opt_df['datetime'])
opt_df['total_victims'] = opt_df['dead_count'] + opt_df['injured_count']
opt_df['hour'] = opt_df['datetime'].dt.hour
opt_df['day_of_week'] = opt_df['datetime'].dt.dayofweek # 0=пн, 6=вс
opt_df['is_fatal'] = opt_df['dead_count'] > 0

print("Добавлены новые столбцы:")
print(opt_df[['datetime', 'dead_count', 'injured_count', 'total_victims', 'hour',
'day_of_week', 'is_fatal']].head())
print("\nТипы новых столбцов:")
print(opt_df[['total_victims', 'hour', 'day_of_week', 'is_fatal']].dtypes)
print(f"\nОбщее      число      пострадавших      (сумма):
{opt_df['total_victims'].sum()}")
print(f"Доля ДТП с погибшими: {opt_df['is_fatal'].mean():.2%}")
```

Добавлены новые столбцы:

	datetime	dead_count	injured_count	total_victims	hour \
0	2015-01-01 06:30:00	0	1	1	6
1	2015-01-02 01:20:00	0	1	1	1
2	2015-01-02 03:50:00	0	1	1	3
3	2015-01-02 14:25:00	0	1	1	14
4	2015-01-03 19:55:00	0	1	1	19

	day_of_week	is_fatal
0	3	False
1	4	False
2	4	False
3	4	False
4	5	False

Типы новых столбцов:

total_victims	int8
hour	int32
day_of_week	int32

```
is_fatal      bool
dtype: object
```

Общее число пострадавших (сумма): 730

Доля ДТП с погибшими: 10.60%

8. Построить минимум один составной фильтр через loc/query и интерпретировать число полученных строк.

```
subset_loc = opt_df.loc[
    (opt_df['total_victims'] > 0) &
    (opt_df['light'] == 'В темное время суток, освещение отсутствует'),
    ['datetime', 'category', 'severity', 'total_victims', 'light']
]
print(f"Число строк, удовлетворяющих условию (ДТП с пострадавшими в темноте без освещения): {len(subset_loc)}")
print(subset_loc.head())
```

```
subset_query = opt_df.query('total_victims > 0 and light == "В темное время суток, освещение отсутствует"')
print(f"\nЧисло строк, удовлетворяющих условию (ДТП с пострадавшими в темноте без освещения): {len(subset_query)}")
print(subset_query[['datetime', 'category', 'severity', 'total_victims', 'light']].head())
```

```
print("\nИнтерпретация:")
if len(subset_loc) > 0:
    print(f"В выборке из 500 записей {len(subset_loc)} ДТП с пострадавшими произошли в условиях темноты без освещения. Это составляет {len(subset_loc)/len(opt_df)*100:.1f}% от всех ДТП.")
    print("Это показывает, что отсутствие освещения может быть фактором риска, но для подтверждения нужен более глубокий анализ.")
else:
    print("В выборке нет ДТП с пострадавшими в условиях темноты без освещения.")
```

Число строк, удовлетворяющих условию (ДТП с пострадавшими в

темноте без освещения): 54

	datetime	category	severity	total_victims \	
0	2015-01-01 06:30:00	Столкновение	Легкий	1	
4	2015-01-03 19:55:00	Наезд на пешехода	Тяжёлый	1	
6	2015-01-07 02:00:00	Столкновение	Легкий	2	
42	2015-03-16 19:20:00	Столкновение	Тяжёлый	6	
44	2015-03-25 23:45:00	Съезд с дороги	С погибшими	2	

light

0 В темное время суток, освещение отсутствует
4 В темное время суток, освещение отсутствует
6 В темное время суток, освещение отсутствует
42 В темное время суток, освещение отсутствует
44 В темное время суток, освещение отсутствует

Число строк, удовлетворяющих условию (ДТП с пострадавшими в темноте без освещения): 54

	datetime	category	severity	total_victims \	
0	2015-01-01 06:30:00	Столкновение	Легкий	1	
4	2015-01-03 19:55:00	Наезд на пешехода	Тяжёлый	1	
6	2015-01-07 02:00:00	Столкновение	Легкий	2	
42	2015-03-16 19:20:00	Столкновение	Тяжёлый	6	
44	2015-03-25 23:45:00	Съезд с дороги	С погибшими	2	

light

0 В темное время суток, освещение отсутствует
4 В темное время суток, освещение отсутствует
6 В темное время суток, освещение отсутствует
42 В темное время суток, освещение отсутствует
44 В темное время суток, освещение отсутствует

Интерпретация:

В выборке из 500 записей 54 ДТП с пострадавшими произошли в условиях темноты без освещения. Это составляет 10.8% от всех ДТП.

Это показывает, что отсутствие освещения может быть фактором риска, но для подтверждения нужен более глубокий анализ.

9. Выполнить минимум две группировки/агрегации, одна из которых должна использовать несколько агрегатных функций.

Группировка 1: по категории ДТП с несколькими агрегатами

```
group1 = (opt_df.groupby('category', observed=True)
```

```
    .agg(
        count=('id', 'size'),
        avg_participants=('participants_count', 'mean'),
        avg_victims=('total_victims', 'mean'),
        max_victims=('total_victims', 'max'),
        fatal_rate=('is_fatal', 'mean')
    )
    .sort_values('count', ascending=False)
    .round(2))
```

```
print("Группировка 1: по категории ДТП")
```

```
print(group1)
```

Группировка 2: по типу освещения с несколькими агрегатами

```
group2 = (opt_df.groupby('light', observed=True)
```

```
    .agg(
        count=('id', 'size'),
        avg_victims=('total_victims', 'mean'),
        max_victims=('total_victims', 'max'),
        fatal_rate=('is_fatal', 'mean')
    )
    .sort_values('count', ascending=False)
    .round(2))
```

```
print("\nГруппировка 2: по типу освещения")
```

```
print(group2)
```

Группировка 1: по категории ДТП

	count	avg_participants	avg_victims	max_victims \
category				
Столкновение	158	3.12	1.70	8
Наезд на пешехода	135	2.11	1.05	3
Опрокидывание	69	2.10	1.75	10
Съезд с дороги	68	1.90	1.47	3

Наезд на препятствие	35	1.77	1.46	3
Наезд на стоящее ТС	24	2.88	1.50	4
Наезд на велосипедиста	6	2.00	1.00	1
Иной вид ДТП	3	1.67	1.00	1
Падение пассажира	2	2.00	1.00	1

fatal_rate

category

Столкновение	0.09
Наезд на пешехода	0.07
Опрокидывание	0.16
Съезд с дороги	0.18
Наезд на препятствие	0.09
Наезд на стоящее ТС	0.12
Наезд на велосипедиста	0.00
Иной вид ДТП	0.00
Падение пассажира	0.00

Группировка 2: по типу освещения

count avg_victims max_victims \

light

Светлое время суток	305	1.47	10	
В темное время суток, освещение включено	109	1.39		5
В темное время суток, освещение отсутствует	54	1.72		6
Сумерки	27	1.19	2	
В темное время суток, освещение не включено	4	1.25		2
Не установлено	1	1.00	1	

fatal_rate

light

Светлое время суток	0.10
В темное время суток, освещение включено	0.07
В темное время суток, освещение отсутствует	0.17
Сумерки	0.07
В темное время суток, освещение не включено	0.50
Не установлено	1.00

10. Исследовать не менее двух числовых признаков: описательная статистика, корреляция и один способ поиска потенциальных выбросов.

```
num_cols = ['participants_count', 'dead_count', 'injured_count', 'total_victims', 'hour', 'day_of_week']
```

```
print("\nОписательная статистика числовых признаков")
print(opt_df[num_cols].describe().round(2))
```

```
print("\nКорреляционная матрица")
corr = opt_df[num_cols].corr()
print(corr.round(3))
```

```
print("\nПоиск выбросов для total_victims (IQR)")
q1 = opt_df['total_victims'].quantile(0.25)
q3 = opt_df['total_victims'].quantile(0.75)
iqr = q3 - q1
lower = q1 - 1.5 * iqr
upper = q3 + 1.5 * iqr
outliers = opt_df[(opt_df['total_victims'] < lower) | (opt_df['total_victims'] > upper)]
print(f"Q1 = {q1:.2f}, Q3 = {q3:.2f}, IQR = {iqr:.2f}")
print(f"Границы: [{lower:.2f}; {upper:.2f}]")
print(f"Число выбросов: {len(outliers)} ({len(outliers)/len(opt_df)*100:.2f}%)")
print("Первые 5 выбросов:")
print(outliers[['datetime', 'category', 'total_victims', 'dead_count', 'injured_count']].head())
```

Описательная статистика числовых признаков

	participants_count	dead_count	injured_count	total_victims	hour \
count	500.00	500.00	500.00	500.00	500.00
mean	2.41	0.12	1.34	1.46	13.34
std	1.33	0.38	0.98	1.02	6.40
min	1.00	0.00	0.00	1.00	0.00
25%	2.00	0.00	1.00	1.00	9.00

50%	2.00	0.00	1.00	1.00	14.00
75%	3.00	0.00	1.00	2.00	18.00
max	16.00	3.00	10.00	10.00	23.00

day_of_week	
count	500.00
mean	3.10
std	2.09
min	0.00
25%	1.00
50%	3.00
75%	5.00
max	6.00

Корреляционная матрица

	participants_count	dead_count	injured_count \
participants_count	1.000	0.154	0.646
dead_count	0.154	1.000	-0.078
injured_count	0.646	-0.078	1.000
total_victims	0.676	0.293	0.930
hour	-0.010	-0.021	-0.037
day_of_week	-0.032	-0.008	-0.009

	total_victims	hour	day_of_week
participants_count	0.676	-0.010	-0.032
dead_count	0.293	-0.021	-0.008
injured_count	0.930	-0.037	-0.009
total_victims	1.000	-0.044	-0.012
hour	-0.044	1.000	-0.083
day_of_week	-0.012	-0.083	1.000

Поиск выбросов для total_victims (IQR)

Q1 = 1.00, Q3 = 2.00, IQR = 1.00

Границы: [-0.50; 3.50]

Число выбросов: 18 (3.60%)

Первые 5 выбросов:

datetime	category	total_victims	dead_count \
----------	----------	---------------	--------------

12	2015-01-23 01:15:00	Столкновение	5	0
42	2015-03-16 19:20:00	Столкновение	6	0
51	2015-04-10 20:00:00	Столкновение	5	0
80	2015-05-24 20:00:00	Опрокидывание	5	2
119	2015-07-04 04:55:00	Опрокидывание	4	1

	injured_count
12	5
42	6
51	5
80	3
119	3

11. Построить не менее четырёх осмысленных визуализаций: категориальное сравнение, распределение, взаимосвязь и четвёртый график по структуре собственного набора. При наличии времени четвертым графиком должен быть временной ряд.

```
import matplotlib.pyplot as plt
```

1. Столбчатая диаграмма: распределение ДТП по категориям

```
plt.figure(figsize=(10, 5))
category_counts = opt_df['category'].value_counts()
category_counts.plot(kind='bar', color='skyblue')
plt.title('Распределение ДТП по категориям')
plt.xlabel('Категория ДТП')
plt.ylabel('Число случаев')
plt.xticks(rotation=45, ha='right')
plt.tight_layout()
plt.show()
```



2. Гистограмма: распределение числа пострадавших

```
plt.figure(figsize=(10, 5))
plt.hist(opt_df['total_victims'], bins=range(1, 12), edgecolor='white',
color='lightgreen')
plt.title('Распределение числа пострадавших в ДТП')
plt.xlabel('Число пострадавших')
```


```
plt.ylabel('Частота')
plt.xticks(range(1, 12))
plt.tight_layout()
plt.show()
```

```
# 3. Scatter plot: зависимость числа пострадавших от числа участников
plt.figure(figsize=(10, 6))
plt.scatter(opt_df['participants_count'], opt_df['total_victims'], alpha=0.5,
s=30, c='coral')
plt.title('Зависимость числа пострадавших от числа участников')
plt.xlabel('Число участников')
plt.ylabel('Число пострадавших')
plt.grid(True)
plt.tight_layout()
plt.show()
```


```
# 4. Временной ряд: количество ДТП по дням (группировка по дате)
daily_counts = opt_df.groupby(opt_df['datetime'].dt.date).size()
plt.figure(figsize=(12, 5))
daily_counts.plot(kind='line', marker='o', linestyle='-', color='darkblue',
linewidth=2)
plt.title('Динамика количества ДТП по дням')
plt.xlabel('Дата')
plt.ylabel('Число ДТП')
plt.grid(True)
plt.tight_layout()
plt.show()
```



Зависимость числа пострадавших от числа участников



Динамика количества ДТП по дням



Интерпретация

Выводы по фильтрации данных:

Составной фильтр (`total_victims > 0` и `light == "В темное время суток, освещение отсутствует"`) выделил 54 записи (10.8% от всех ДТП). Среди них встречаются случаи с 6 пострадавшими и тяжёлыми последствиями. Это указывает на то, что отсутствие освещения может быть фактором риска. Однако окончательный вывод требует сравнения с другими условиями освещения (например, с включённым освещением), что было сделано в группировках.

Выводы по группировкам и агрегациям.

По категориям ДТП:

- Наиболее частые типы — «Столкновение» (158) и «Наезд на пешехода» (135).
- Наибольшее среднее число пострадавших — у «Опрокидывания» (1.75) и «Столкновения» (1.70).
- Самая высокая доля погибших — у «Съезда с дороги» (18%) и «Опрокидывания» (16%).
- Наезды на велосипедистов и падения пассажиров имеют нулевую долю погибших, но их мало для статистически значимых выводов.

По типу освещения:

- ДТП в светлое время суток составляют большинство (61%).
- В тёмное время без освещения среднее число пострадавших (1.72) выше, чем в светлое время (1.47) и при включённом освещении (1.39).
- Доля ДТП с погибшими в темноте без освещения (17%) значительно выше, чем в светлое время (10%) и при включённом освещении (7%).
- Это подтверждает гипотезу о том, что отсутствие освещения повышает тяжесть ДТП.

Выводы по корреляционному анализу:

- Сильная положительная корреляция между `total_victims` и `injured_count` (0.930) ожидаема, так как это связанные показатели.
- Заметная связь между `participants_count` и `total_victims` (0.676): чем больше участников, тем больше пострадавших.
- Время суток (`hour`) и день недели (`day_of_week`) практически не коррелируют с числовыми показателями тяжести, что указывает на слабое влияние этих факторов на число жертв.

- Корреляционный анализ не выявил неожиданных связей, но подтвердил логичные зависимости.

Выводы по выбросам (правило IQR):

- Правило IQR выявило 18 выбросов (3.6% от выборки) по признаку `total_victims` со значениями от 4 до 10 пострадавших.
- Это случаи массовых ДТП, часто связанные со столкновениями и опрокидываниями.
- Механическое удаление таких строк недопустимо, так как они могут содержать важную информацию о факторах тяжёлых происшествий. В учебном анализе мы лишь фиксируем их наличие.

Выводы по визуализациям:

- Столбчатая диаграмма: подтверждает доминирование столкновений и наездов на пешеходов. Остальные категории встречаются реже.
- Гистограмма: распределение числа пострадавших сильно скошено вправо: большинство ДТП имеют 1 пострадавшего, случаи с 4+ пострадавшими единичны.
- Scatter plot: подтверждает положительную связь между числом участников и числом пострадавших, но с большим разбросом. Выбросы с большим числом пострадавших видны на графике.
- Временной ряд: показывает неравномерность ДТП по дням, но из-за малого периода (первые месяцы 2015 года) сезонные закономерности не прослеживаются. Демонстрирует возможность временного анализа при наличии более полных данных.

Экспорт

CSV сохранён: output\ntp_clean.csv

Parquet сохранён: output\ntp_clean.parquet

JSON сохранён: output\ntp_clean.json

Размеры файлов

ntp_clean.csv : 0.34 MiB

ntp_clean.json : 0.47 MiB

ntp_clean.parquet : 0.04 MiB

Проверка round-trip (повторное чтение)

CSV: загружено 500 строк, 22 столбцов

Parquet: загружено 500 строк, 22 столбцов

Типы из Parquet:

id	int32
tags	str
category	category
region	str
county	category
address	str
longitude	float64
latitude	float64
nearby	str
datetime	datetime64[us]
light	category
weather	category
road_conditions	category
participants_count	int8
participant_categories	category
severity	category
dead_count	int8
injured_count	int8
total_victims	int8
hour	int32
day_of_week	int32
is_fatal	bool

dtype: object

JSON: загружено 500 строк, 22 столбцов

Итог

Выводы по данным:

1. Частота категорий ДТП – в выборке доминируют Столкновение (158 случаев, 31.6%) и Наезд на пешехода (135 случаев, 27.0%). Это указывает на то, что данные преимущественно отражают городские ДТП с участием пешеходов и столкновения транспортных средств.

2. Тяжесть и число пострадавших – большинство ДТП (около 80%) имеют 1–2 пострадавших. Среднее число пострадавших – 1.46, медиана – 1. ДТП с большим числом пострадавших (>3) встречаются редко (менее 5% случаев), но именно они дают максимальные значения (до 10 пострадавших).

3. Фактор освещения – ДТП в тёмное время суток без освещения составляют 10.8% от всех случаев, но доля ДТП с погибшими в этой группе выше (17%) по сравнению со светлым временем суток (10%) и освещёнными участками (7%). Это согласуется с предположением, что плохое освещение повышает риск тяжёлых последствий.

4. Связь участников и пострадавших – корреляция между числом участников и числом пострадавших составляет 0.676 (умеренная положительная). Это означает, что при увеличении числа участников ДТП возрастает и количество пострадавших, но связь не является строгой (разброс велик).

5. Временная динамика – в выборке за период январь–август 2015 года наблюдаются отдельные дни с повышенным числом ДТП (пики), но устойчивых трендов не видно из-за малого объёма данных (500 записей).

Ограничения анализа:

1. Репрезентативность выборки – данные содержат только первые 500 записей из общего массива, при этом все записи относятся к Магаданской области. Это не позволяет делать выводы по всей России и не отражает региональные различия в статистике ДТП.

2. Пропуски и неполнота данных – в столбце address есть 13 пропусков, а некоторые категориальные признаки (например, road_conditions, weather) могут иметь неполные или неточные значения, что ограничивает глубину анализа этих факторов.